技术汇报 · 当前仓库实现

华山多模态生化指标预测

端到端训练 Pipeline 说明

目标：利用基线 L3 中心 2.5D CT、基线生化、人口学信息与未来查询时间，联合预测未来 0–2 年的 10 项生化指标。

项目快照	当前数据规模	文档用途
代码与数据截至 2026-09-01	274 人 / 594 条随访；CT 可用后 252 人 / 560 条	导师汇报、方案评审、实验复现

Prepared from the executable repository pipeline

汇报摘要

一句话结论 当前仓库已经形成可运行的“数据校验 → CT 预处理 → 患者级划分 → 多模态建模 → 训练/早停 → 独立测试”闭环；当前最需要补齐的是正式训练结果、归一化来源元数据以及更严格的临床验证设计。

这套 pipeline 的核心设计不是把一次随访当作一个独立患者，而是先按患者划分数据，再把每个随访时间点作为一个训练样本。这样既保留纵向信息，又避免同一患者同时出现在训练集与测试集造成泄漏。

1. 预测任务：输入一位患者的基线状态与未来时间 t，输出 HBA1C、TG、CHO、HDL、LDL、ALB、BUN、UA、CRE、CysC 共 10 项未来值。
2. CT 表征：L3 中心相邻 3 层作为 3 通道输入，使用 ImageNet ResNet18 提取 128 维向量；默认冻结 backbone，仅训练投影与后续模块。
3. 缺失机制：前 9 项核心指标要求完整；CysC 允许缺失，并用显式 mask 同时作用于输入编码与损失计算。
4. 训练策略：AdamW、masked Huber loss、梯度裁剪、可选 AMP、验证集早停、best/last 双 checkpoint 与随机数状态恢复。
5. 当前验证：252 个有效 CT 数组通过全量预检；合成数据端到端冒烟测试通过前向、反向、更新与 checkpoint 重载。

当前数据快照

数据层级	患者数	观察数	CysC 目标已观测	说明
清洗后 0–2 年长表	274	594	440	尚未按 CT 可用性过滤
训练集（CT 可用）	177	381	280	患者级 70% 划分后再与 CT 内连接
验证集（CT 可用）	37	74	62	仅用于早停与模型选择

数据层级	患者数	观察数	CysC 目标已观测	说明
测试集（CT 可用）	38	105	83	训练结束后一次性评估
多模态有效队列	252	560	425	22 名生化患者因 CT 失败/缺失被排除

数据说明：`patient_split.csv` 原始划分为 192/41/41 名患者；与 CT 清单中成功或已存在的 2.5D 数组内连接后，有效划分变为 177/37/38 名患者。CT 清单还包含 27 名无对应生化长表的患者。

1. 全流程总览

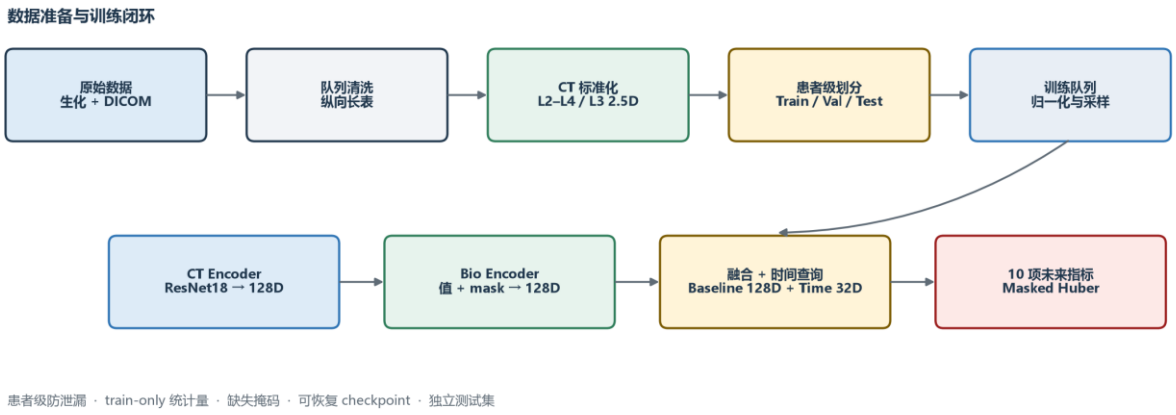


图 1 从原始数据到独立测试评估的闭环

主训练入口 `train.py` 从已经清洗好的 Excel 长表和 CT manifest 开始；`data_washing/scripts/` 属于更上游的数据构建链路。二者通过固定字段契约衔接，而不是由一个总控脚本自动串联。

输入—处理—输出

6. 原始侧：季度生化工作簿、患者匹配结果、DICOM 序列及 CT 拍摄时间。
7. 清洗侧：构造每位患者的 T0 基线和 T1…Tn 随访，转成长表并限制 $0 < t_days \le 730$。
8. 影像侧：DICOM/NIfTI 统一、L2/L3/L4 分割、L2–L4 ROI、L3 中心三层 2.5D 数组。
9. 学习侧：患者级划分、CT 可用性过滤、仅训练集拟合统计量、患者均衡采样。
10. 模型侧：CT、生化、人口学三路形成基线状态，再与未来时间嵌入共同解码。
11. 结果侧：best.pt、last.pt、history.json、test_metrics.json、test_predictions.csv。

2. 上游数据清洗与纵向队列

上游脚本的职责是把多个来源的 CT 匹配记录和 2018–2021 年季度生化记录整理成模型可读取的统一 Excel。现有训练代码不会自动重跑这些步骤，因此正式实验应把清洗产物版本与脚本提交一起冻结。

2.1 主要处理逻辑

12. 患者匹配与 CT 序列选择：按 PatientIntraID 查找候选 DICOM 目录；优先最长可读序列，再按样本日期与 DICOM 日期的绝对差最小选择。
13. CT 时间读取：DICOM 日期优先级为 AcquisitionDateTime → AcquisitionDate → SeriesDate → StudyDate；冲突进入审查表。
14. 同日重复去重：同姓名、同样本日期的候选仅在 DICOM 日期证据唯一时自动保留最接近者，否则整组不删并写入审计 CSV。
15. 纵向生化构建：用患者号与姓名匹配季度记录；T0 之后的日期按升序形成 T1、T2…；同日多条记录选择非空字段最多的一条。
16. 训练长表清洗：基线信息复制到每条随访记录；前 9 项核心指标默认要求完整，CysC 保留 NaN 并生成观测 mask；不在此阶段做归一化。

防泄漏原则 任何均值、标准差或 CysC 中位数都不能在全队列上拟合；这些统计量必须等患者级划分与 CT 可用性过滤完成后，只使用最终训练队列计算。

2.2 清洗后工作簿结构

工作表	作用
baseline	每位患者一条基线记录及 CT 路径
longitudinal_all	所有可用纵向记录

工作表	作用
model_long_all	满足模型字段契约的长表
model_long_0_2y	训练默认使用的 0–2 年窗口，共 594 条观察
qc_summary	清洗数量、缺失与时间窗口质控汇总

3. CT 预处理链路

CT 预处理以 `ct_manifest.csv` 为唯一状态账本。每个患者独立执行，失败会记录 status/message，不会静默删除；所有生成路径可保存为相对路径，便于迁移。

阶段	脚本	输入	输出	关键 QC
1	convert_dicom.py	DICOM 目录或 NIfTI	统一为 ct.nii.gz	检查 3D、spacing、direction、origin 与有限体素；DICOM 用 dcm2niix
2	segment_vertebrae.py	ct.nii.gz	L2/L3/L4 mask	TotalSegmentator --roi_subset；验证 mask 与 CT 几何一致且非空
3	extract_l2_l4_roi.py	CT + 三个椎体 mask	l2_l4_roi.nii.gz	统一 LPS；按 L2–L4 并集加 20 mm z margin；重采样至 1.5×1.5×2.0 mm
4	build_25d.py	ROI + L3 中心层	l3_25d.npy	取相邻 3 个轴位层；HU 窗 [-200,300]；线性缩放到 224×224 与 [0,1] float32

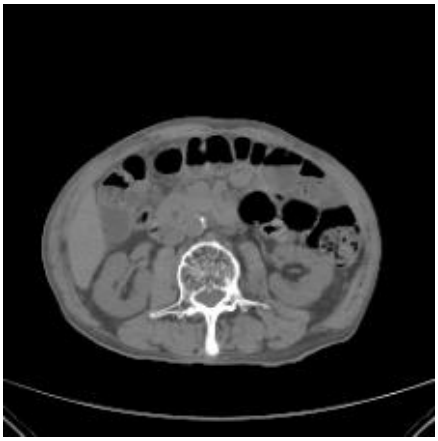


图 2　仓库中已生成的匿名 L3 中心层预览示例（仅展示图像，不含患者标识）

当前处理结果 test/ct_manifest.csv 共 305 条：转换成功/已存在 303，椎体分割成功/已存在 279，ROI 与 2.5D 构建成功/已存在 279；其中与生化队列重叠且进入训练系统的 CT 为 252 例。

4. Dataset、划分与标准化

4.1 样本定义

一条 Dataset item 对应“一位患者的一次未来随访”，而不是一位患者。该患者的同一份基线 CT 与基线生化会被复用于不同 t_days 的目标，因此训练采样必须处理患者随访次数不均衡。

键	形状 / 类型	含义
ct_25d	float32 [B,3,H,W]	L3 中心 3 层，范围 [0,1]，默认 224×224
bio_base	float32 [B,10]	训练集统计量标准化后的基线生化
base_mask	float32 [B,10]	1=观测；0=缺失；当前仅 CysC 可缺失
demographics	float32 [B,2]	[标准化年龄, 性别编码]；女=0、男=1
time	float32 [B,1]	t_days / 365.25，单位年
target	float32 [B,10]	标准化未来生化目标；缺失 CysC 位置填 0 占位
target_mask	float32 [B,10]	决定损失与指标中哪些目标有效

4.2 患者级划分与 CT 内连接

17. 固定随机种子 42，将 274 名唯一患者按 70%/15%/15% 分为 192/41/41。
18. 再与 CT manifest 中 build_25d_status∈{success, skipped_existing} 的记录做 many-to-one 内连接。
19. 有效患者变为 177/37/38，三组患者集合严格不相交；同一患者的所有随访必须留在同一 split。
20. 训练集使用 WeightedRandomSampler，单条观察权重 = 1 / 该患者观察数，使每位患者在期望上具有相同抽样贡献。

4.3 仅训练集归一化

基线统计量先对每位训练患者去重，使重复出现的基线不因随访多而被重复计权；目标统计量按训练观察拟合。CysC 基线缺失先用训练患者中位数填补，再标准化；CysC 目标缺失不参与拟合或损失。年龄同样仅用训练患者拟合。

当前仓库提示 现有 normalization.json 能被兼容读取，但没有 schema v2 队列元数据。默认 train.py 会在当前 CT 可用训练队列上重新拟合并覆盖；正式实验不应使用 --reuse-stats，除非统计文件中的患者、split 与 manifest 哈希完全匹配。

5. 模型结构

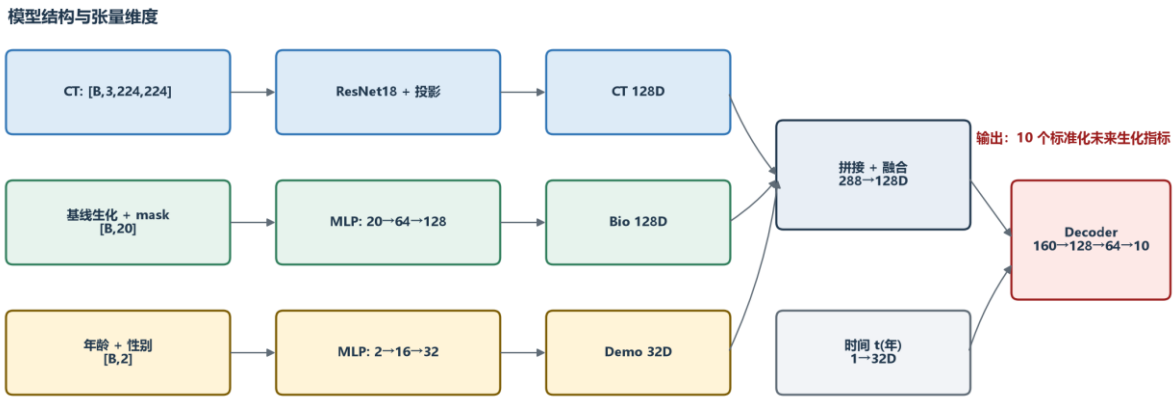


图3 当前多模态预测模型及默认维度

模块	结构	输出	默认训练状态
CTEncoder	ImageNet 归一化 → ResNet18(512D) → Dropout/Linear/LayerNorm/GELU	128D	backbone 冻结；投影层训练
BiochemistryEncoder	[10 个值 + 10 个 mask] → 64 → 128，含 LayerNorm/GELU/Dropout	128D	全部训练
DemographicsEncoder	[年龄, 性别] → 16 → 32	32D	全部训练
Baseline fusion	拼接 128+128+32=288 → 128 → 128	128D	全部训练
Time encoder	1 → 32 → 32	32D	全部训练
Decoder	[baseline 128 + time 32] → 128 → 64 → 10	10 个标准化预测	全部训练

默认总参数量约 11.34M；冻结 ResNet18 backbone 后，可训练参数约 161k。其目的是在仅 177 名 CT 可用训练患者的规模下减少过拟合风险，同时保留影像投影、双模态融合与时间解码的学习能力。

时间查询的含义 模型先生成不依赖未来时间的 baseline_state，再把任意 t（年）编码后联合解码。因此同一患者可在不同 t_days 上产生不同预测，但当前实现没有显式单调性或生理动力学约束。

6. 训练循环与 checkpoint

6.1 默认超参数

项目	默认值	说明
batch size	16	训练集患者均衡采样；验证/测试顺序读取
epochs	50	由 early stopping 可能提前终止
optimizer	AdamW	learning rate=1e-3；weight decay=1e-4
loss	Masked Huber, δ=1	按所有有效生化元素求平均
patience	10	验证损失连续 10 轮不改善则停止
gradient clipping	1.0	对全模型梯度范数裁剪
AMP	默认关闭	仅 CUDA 且显式 --amp 时启用
CT backbone	默认冻结	--finetune-ct-backbone 可解冻
seed	42	Python、NumPy、PyTorch 与 CUDA 一并设定

6.2 每个 epoch 的执行顺序

21. 从患者均衡 sampler 取 batch，并把所有张量移动到目标设备。
22. CT、生化、人口学与时间分别编码，输出 10 维标准化预测。
23. 仅在 target_mask=1 的元素上计算 Huber loss；反向传播后裁剪梯度并更新 AdamW。
24. 在验证集无梯度评估 masked Huber loss；若改善则覆盖 best.pt。
25. 每轮都原子写入 last.pt 和 history.json；保存优化器、AMP scaler、随机数状态、模型配置、归一化统计与训练历史。
26. 早停或完成后，重新加载 best checkpoint，在测试集导出临床单位预测与指标。

6.3 Masked Huber loss

$$L = \Sigma_{ij} m_{ij} \cdot \text{Huber}(\hat{y}_{ij} - y_{ij}; \delta=1) / \Sigma_{ij} m_{ij}$$

这一实现保证 CysC 缺失位置即使 target 中保存了占位值，也不会影响训练损失；训练与验证损失均按有效目标元素数加权汇总。

7. 评估、产物与复现

7.1 评估指标

层级	指标	解释
整体优化目标	masked_huber_loss	所有有效目标元素上的加权平均 Huber loss
每个生化指标	normalized MAE / RMSE	标准化空间误差，便于跨指标比较
每个生化指标	clinical MAE / RMSE	反标准化到原单位后计算，更适合临床解释
宏平均	4 项误差的 marker-wise mean	对有有效样本的指标等权平均
覆盖度	count	每个指标参与评估的有效观察数；CysC 受 mask 影响

7.2 训练目录产物

27. best.pt：验证损失最优模型与完整复现状态。
28. last.pt：最近一轮状态，用于中断续训。
29. history.json：epoch、train loss、val loss 曲线数据。
30. test_metrics.json：整体、宏平均与逐指标误差。
31. test_predictions.csv：患者 ID、未来时间、每个指标的 mask、预测和真实值。

当前结果边界 仓库快照中没有 runs/ 正式训练目录，因此本说明只展示已验证的 pipeline、数据规模与工程状态，不虚构模型性能。向老师汇报时应把后续真实实验的 loss 曲线、逐指标 MAE/RMSE 与置信区间追加到本节。

8. 质量控制与已验证状态

8.1 Preflight 全量检查

已在当前仓库数据上执行完整 preflight（未跳过数组内容检查），结果通过。它验证患者集合、split 隔离、CT 路径、数组 shape/dtype/range、CysC 覆盖和归一化来源一致性。

检查项	当前结果	解释
患者泄漏	通过	train / val / test 患者集合无交集
CT 数组内容	252/252 通过	均为 [3,224,224]、float32、有限且位于 [0,1]
多模态连接	252 人 / 560 条	生化队列 274 人中 22 人无成功 CT
CysC 目标	425 观测 / 135 缺失	train 280/101；val 62/12；test 83/22
外部 CT 工具	当前环境未发现	不影响已生成数组上的训练，但不能在此环境重跑 DICOM/分割
归一化元数据	兼容通过但有警告	现有 JSON 无 schema v2 cohort hashes，应重新拟合

8.2 端到端冒烟测试

`pipeline_smoke_test.py` 已在当前环境运行通过：合成 2.5D 数组 → Dataset/DataLoader → CT/Bio 编码 → 融合与 masked loss → backward → AdamW step → checkpoint 保存/重载，重载后的预测在 atol=1e-6 下完全一致。

9. 风险、局限与下一步

优先级	问题	影响	建议
P0	缺少正式训练与外部验证结果	目前不能回答真实泛化性能	固定当前数据/代码哈希，跑 baseline；报告逐指标误差与 bootstrap 95% CI
P0	comparison_status 中 Count mismatch 较多（168/274）	CT 与生化匹配可靠性可能影响标签质量	逐例审计 mismatch 定义与处理；将状态纳入敏感性分析
P0	现有 normalization.json 无队列元数据	误用旧统计量会造成不可追溯或泄漏风险	由 train.py 默认重新拟合；保存 schema v2 hashes
P1	样本量小、同一患者多随访	深度模型过拟合；观察级 CI 偏乐观	患者级 bootstrap；比较冻结/微调；增加简化基线模型
P1	随机 70/15/15 单次划分	结果对一次划分敏感	在 baseline 稳定后做患者级重复交叉验证或 nested CV
P1	无 CT augmentation 与域偏移评估	扫描协议/设备变化可能降低泛化	加入受控增强；按年份、设备或中心做分层验证
P2	时间仅作为标量 MLP 输入	缺少显式动力学与单调约束	比较 Fourier/time2vec、Δ 预测、混合效应或神经 ODE 方案
P2	只用 L3 邻近 3 层	可能遗漏全身或其他椎体信息	比较 3D ROI、更多层、器官/体成分特征

建议的汇报顺序

32. 先讲临床问题与输入/输出契约：基线多模态 → 任意未来时间 → 10 项生化。
33. 再讲患者级防泄漏与 CysC mask，这是方法可信度的关键。
34. 展示 CT 预处理和模型结构两张图，强调默认冻结 ResNet18 适配小样本。
35. 如实报告当前 preflight 与 smoke test 已通过，但正式性能仍待训练。
36. 最后给出 P0/P1 验证计划，让讨论聚焦在队列质量、统计设计和临床可解释性。

附录 A：推荐执行顺序

A.1 CT 小批量试运行

```
python CT_preparation/convert_dicom.py --input multidataset/huashan_cleaned.xlsx --sheet baseline --
output-root <CT_ROOT> --manifest <CT_ROOT>/ct_manifest.csv --relative-paths --limit 3
python CT_preparation/segment_vertebrae.py --manifest <CT_ROOT>/ct_manifest.csv --output-root
<CT_ROOT> --relative-paths --limit 3
python CT_preparation/extract_l2_l4_roi.py --manifest <CT_ROOT>/ct_manifest.csv --output-root
<CT_ROOT> --target-spacing 1.5 1.5 2.0 --z-margin-mm 20 --relative-paths --limit 3
python CT_preparation/build_25d.py --manifest <CT_ROOT>/ct_manifest.csv --output-root <CT_ROOT> --
num-slices 3 --image-size 224 --window-min -200 --window-max 300 --save-preview --relative-paths --
limit 3
```

A.2 Dataset、预检与训练

```
python multidataset/huashan_dataset.py --input multidataset/huashan_cleaned.xlsx --ct-manifest
<CT_ROOT>/ct_manifest.csv --ct-root <CT_ROOT> --split-file multidataset/patient_split.csv --stats-
file multidataset/normalization.json --fit-stats --smoke-test
python preflight.py --input multidataset/huashan_cleaned.xlsx --ct-manifest
<CT_ROOT>/ct_manifest.csv --ct-root <CT_ROOT> --split-file multidataset/patient_split.csv --stats-
file multidataset/normalization.json --report runs/preflight.json
python pipeline_smoke_test.py
python train.py --input multidataset/huashan_cleaned.xlsx --ct-manifest <CT_ROOT>/ct_manifest.csv --
ct-root <CT_ROOT> --split-file multidataset/patient_split.csv --stats-file
multidataset/normalization.json --output-dir runs/baseline --batch-size 16 --epochs 50 --learning-
rate 1e-3 --patience 10 --device auto
```

A.3 独立复现评估

```
python evaluate.py --input multidataset/huashan_cleaned.xlsx --ct-manifest <CT_ROOT>/ct_manifest.csv
--ct-root <CT_ROOT> --checkpoint runs/baseline/best.pt --split test --predictions
runs/baseline/test_predictions_reproduced.csv --metrics runs/baseline/test_metrics_reproduced.json
```

附录 B：代码导航

文件	职责
README.md	端到端使用顺序与固定模型契约
data_washing/scripts/*.py	CT/生化匹配、日期审计、纵向工作簿和模型长表清洗
CT_preparation/*.py	DICOM 转换、椎体分割、ROI 与 2.5D 构建
multidataset/split_patients.py	固定种子的患者级 train/val/test 划分
multidataset/huashan_dataset.py	字段校验、CT 连接、train-only 统计量、PyTorch Dataset 与 sampler
CT_modal/ct_encoder.py	ResNet18 CT 编码器与 backbone 冻结逻辑
biochemistry_modal/biochemistry_encoder.py	生化值与缺失 mask 联合编码
fusion_query_modal/fusion_time_query.py	人口学/时间编码、融合解码与 masked Huber loss
multimodal_model.py	统一封装三路编码器与预测头
train.py	训练、早停、checkpoint、最终测试
evaluate.py	checkpoint 恢复、反标准化、逐指标与宏平均指标
preflight.py / pipeline_smoke_test.py	真实数据预检 / 合成数据集成测试

文档依据 本说明根据上述源文件、当前 Excel/CSV/manifest 快照以及实际 preflight、smoke test 运行结果整理；未把尚不存在的训练性能当作既成结果。